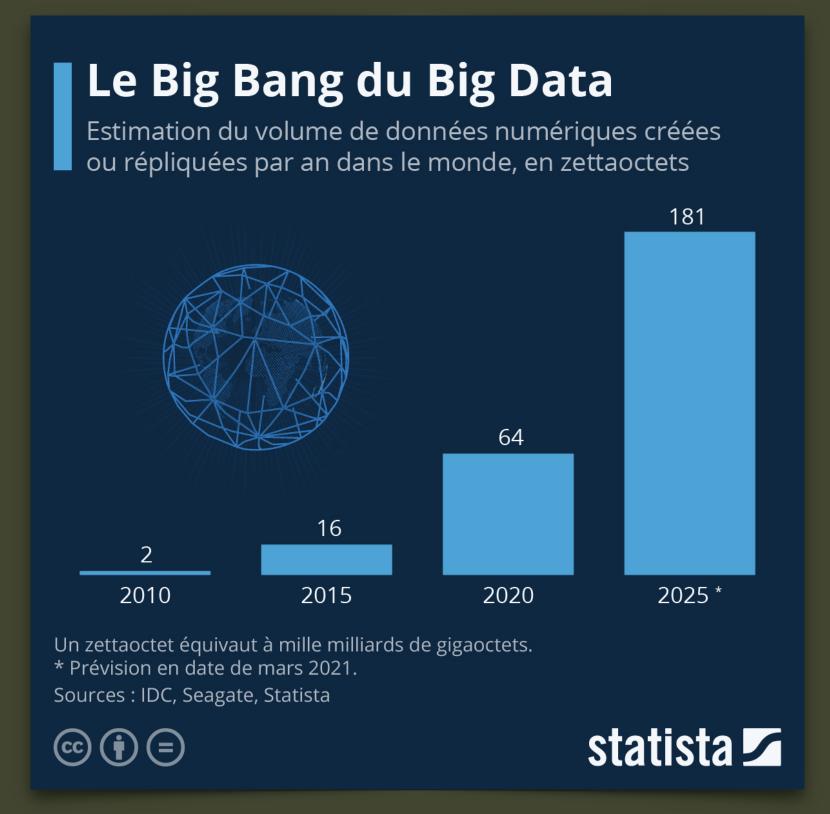


"By 2025, there will be 175 zettabytes of data globally, with 80% of that data being unstructured. Ninety percent of unstructured data is never analyzed."

- Forbes





Activités quotidiennes

Ex : Transactions financières internes, Gestion des stock

Produits et services

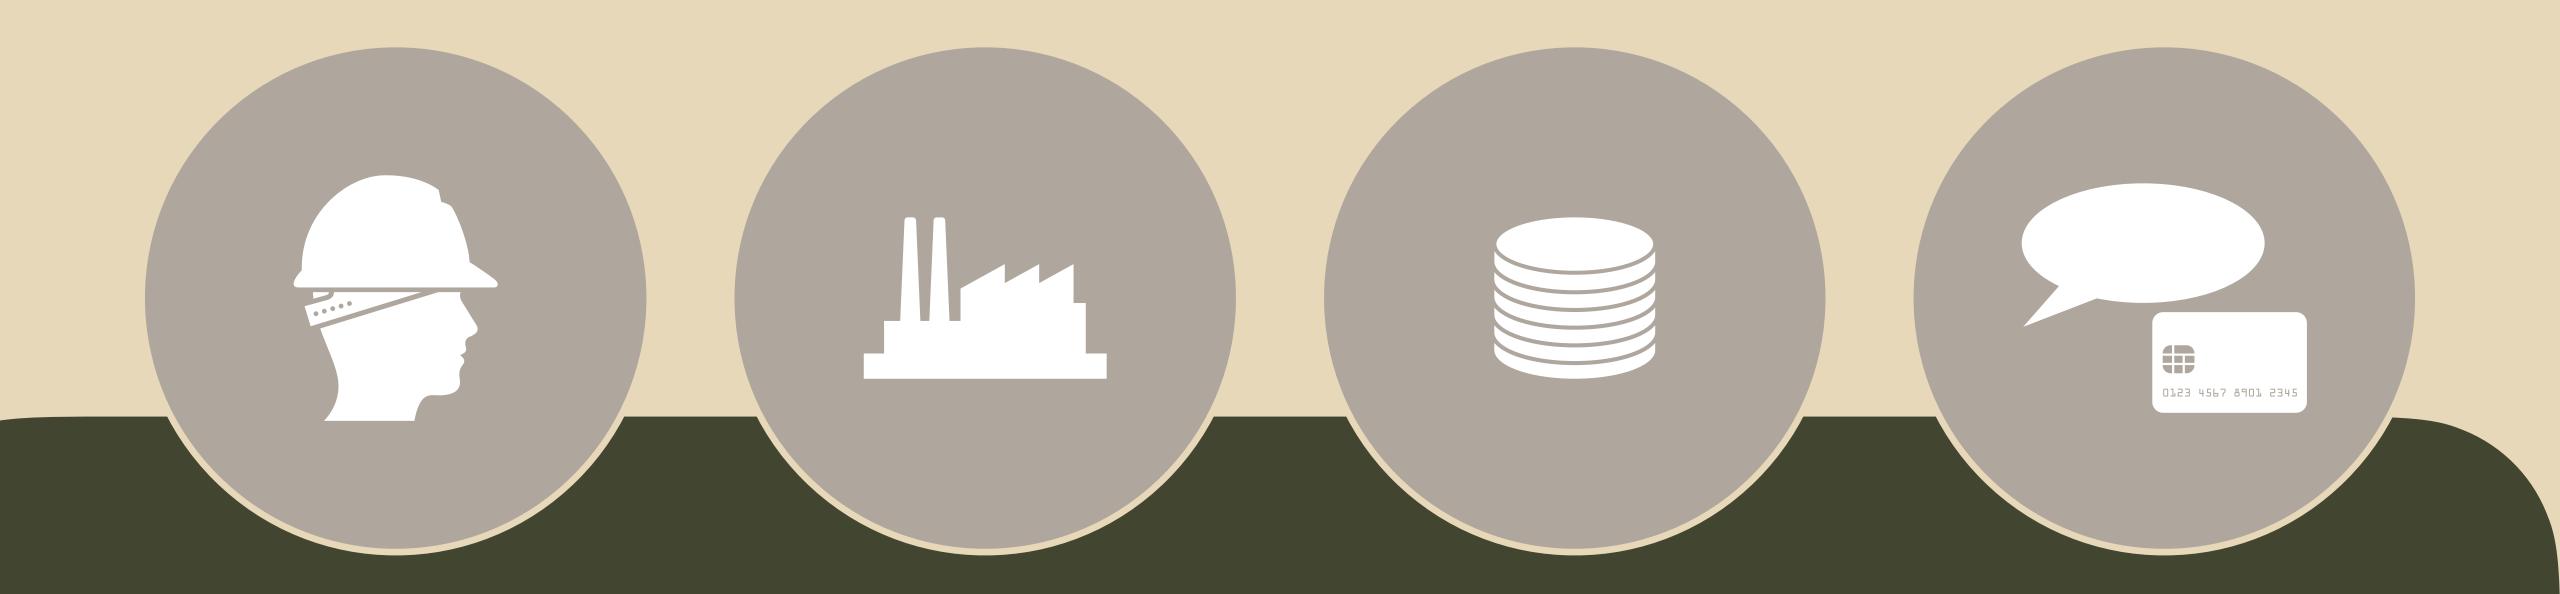
Ex : Statistiques de vente

Données accessibles

Ex : Bases de données publiques, Études de marché

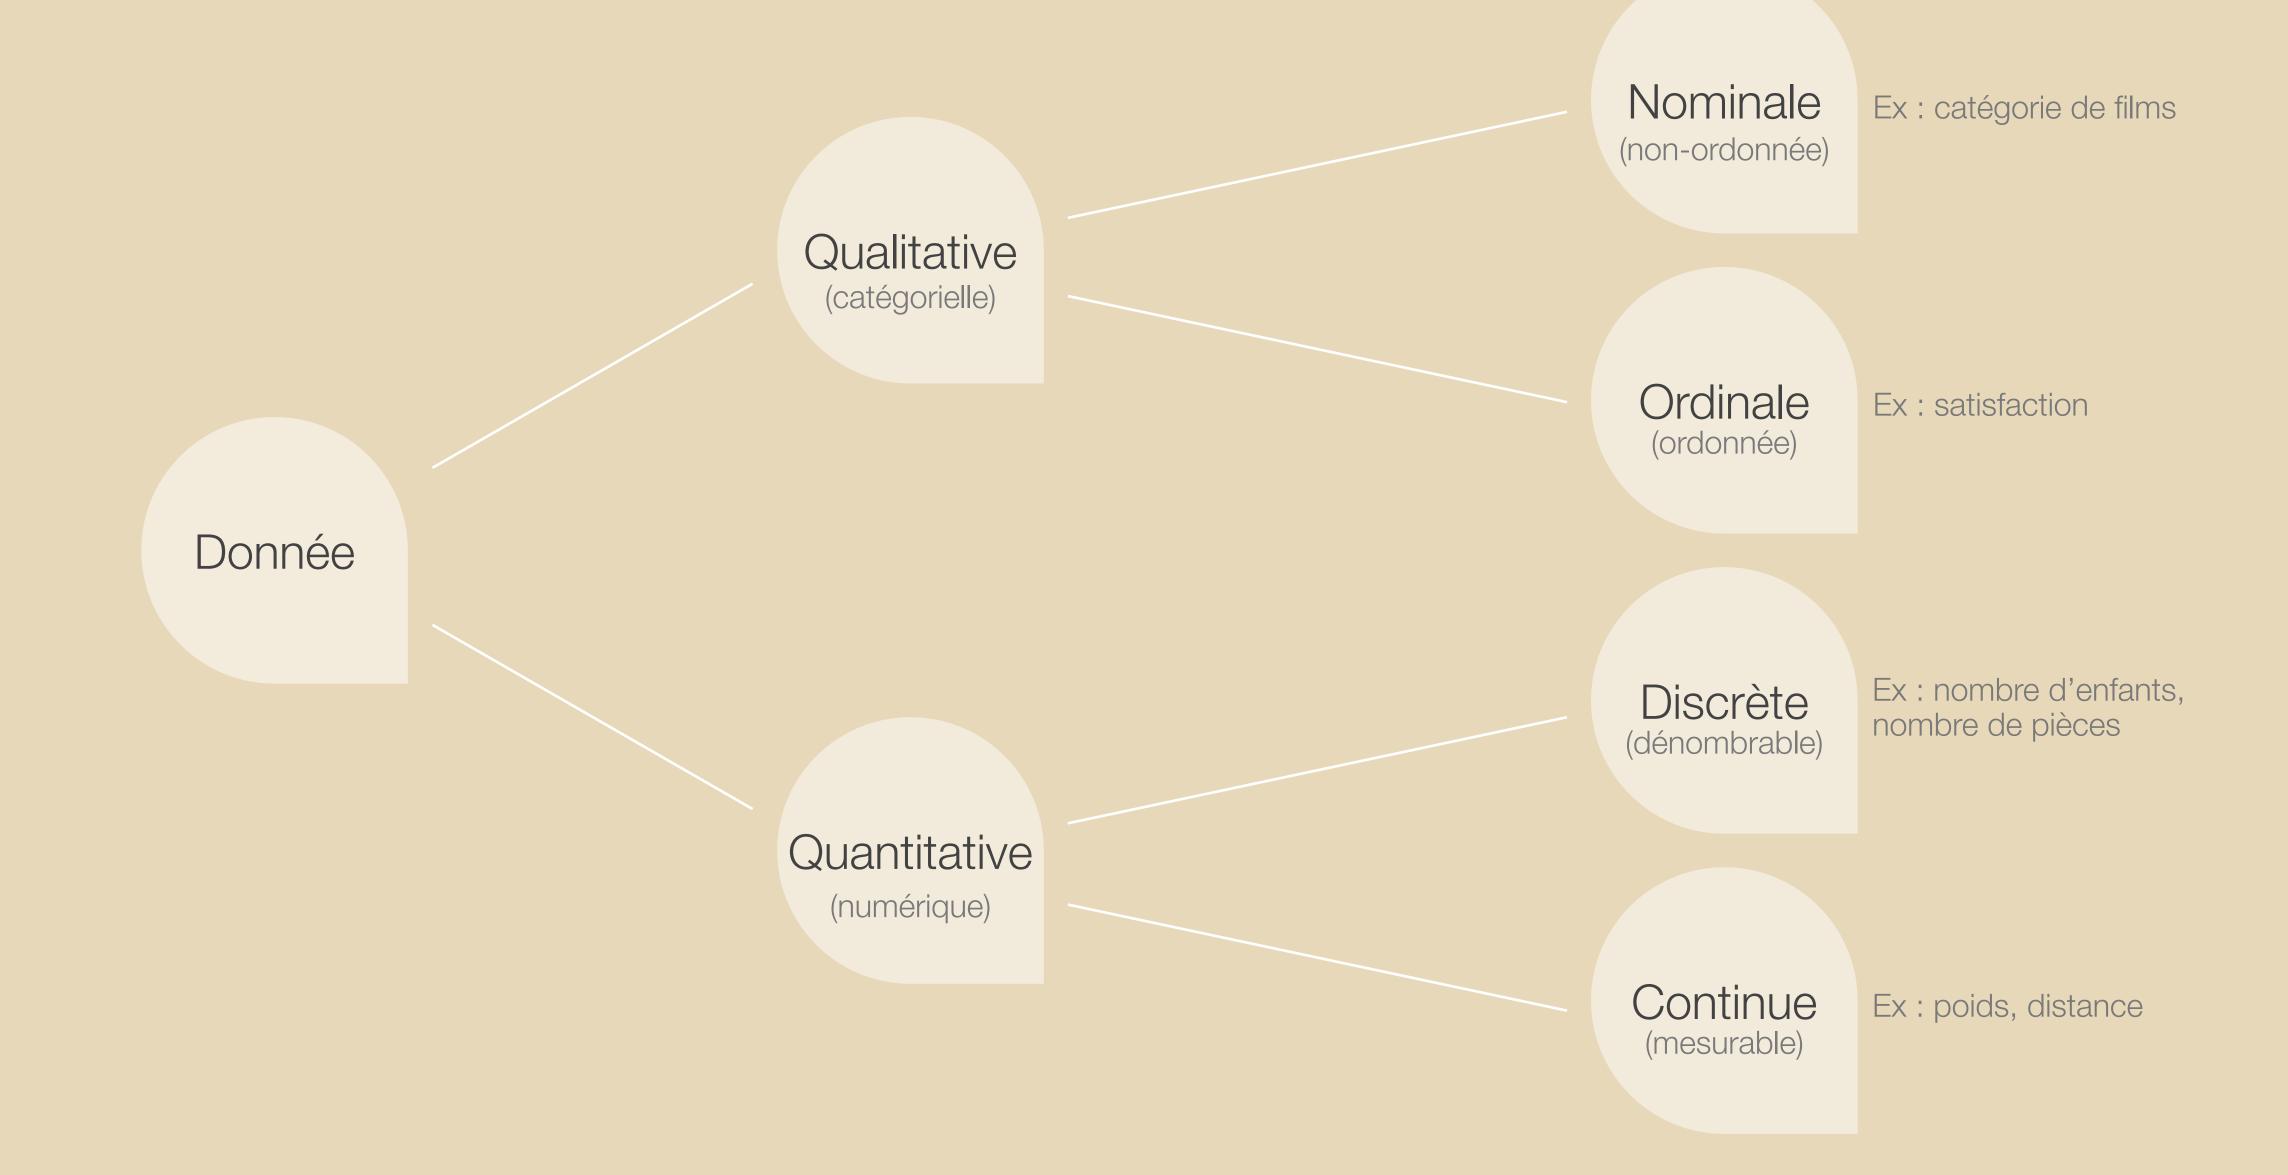
Données crées et fournis par les partenaires

Ex : Avis clients, Données transactionnelles



Déluge de données

Les différentes formes de données



Pipeline ML

Subject: Waiting for your reply

From: prince1@test.com

We are delighted to inform you that you won 1.000.000 (one million) US Dollars. To claim the prize, you need to pay a small processing fee. Please transfer \$10 to our PayPal account at prince@test.com. Once we receive the money, we will start the transfer.

Congratulations again!



Pipeline ML

Subject: Waiting for your reply

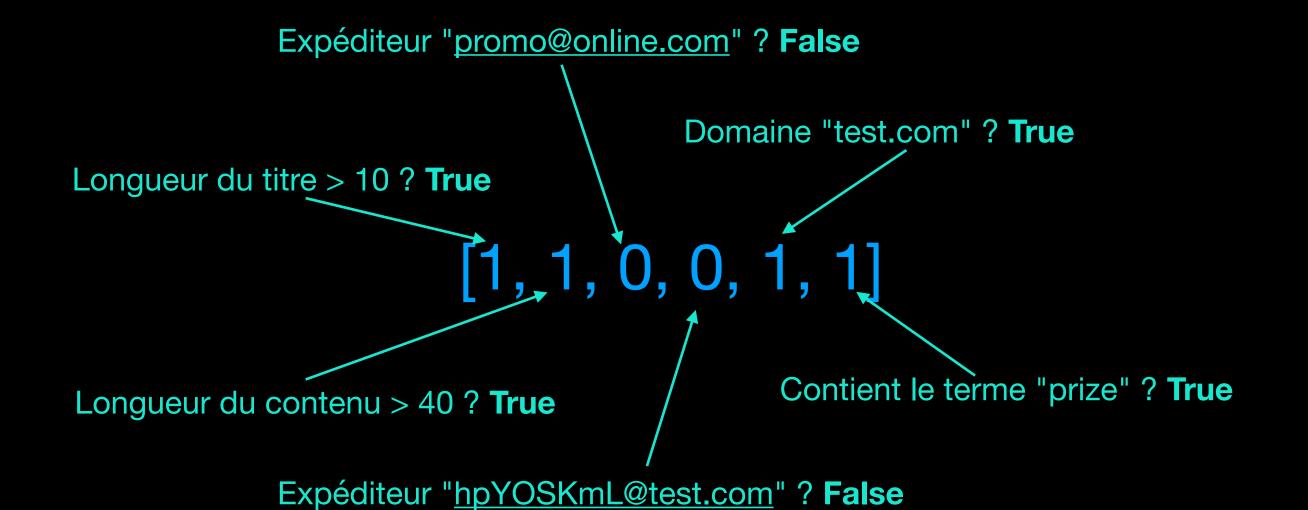
From: prince1@test.com

We are delighted to inform you that you won 1.000.000 (one million) US Dollars. To claim the prize, you need to pay a small processing fee. Please

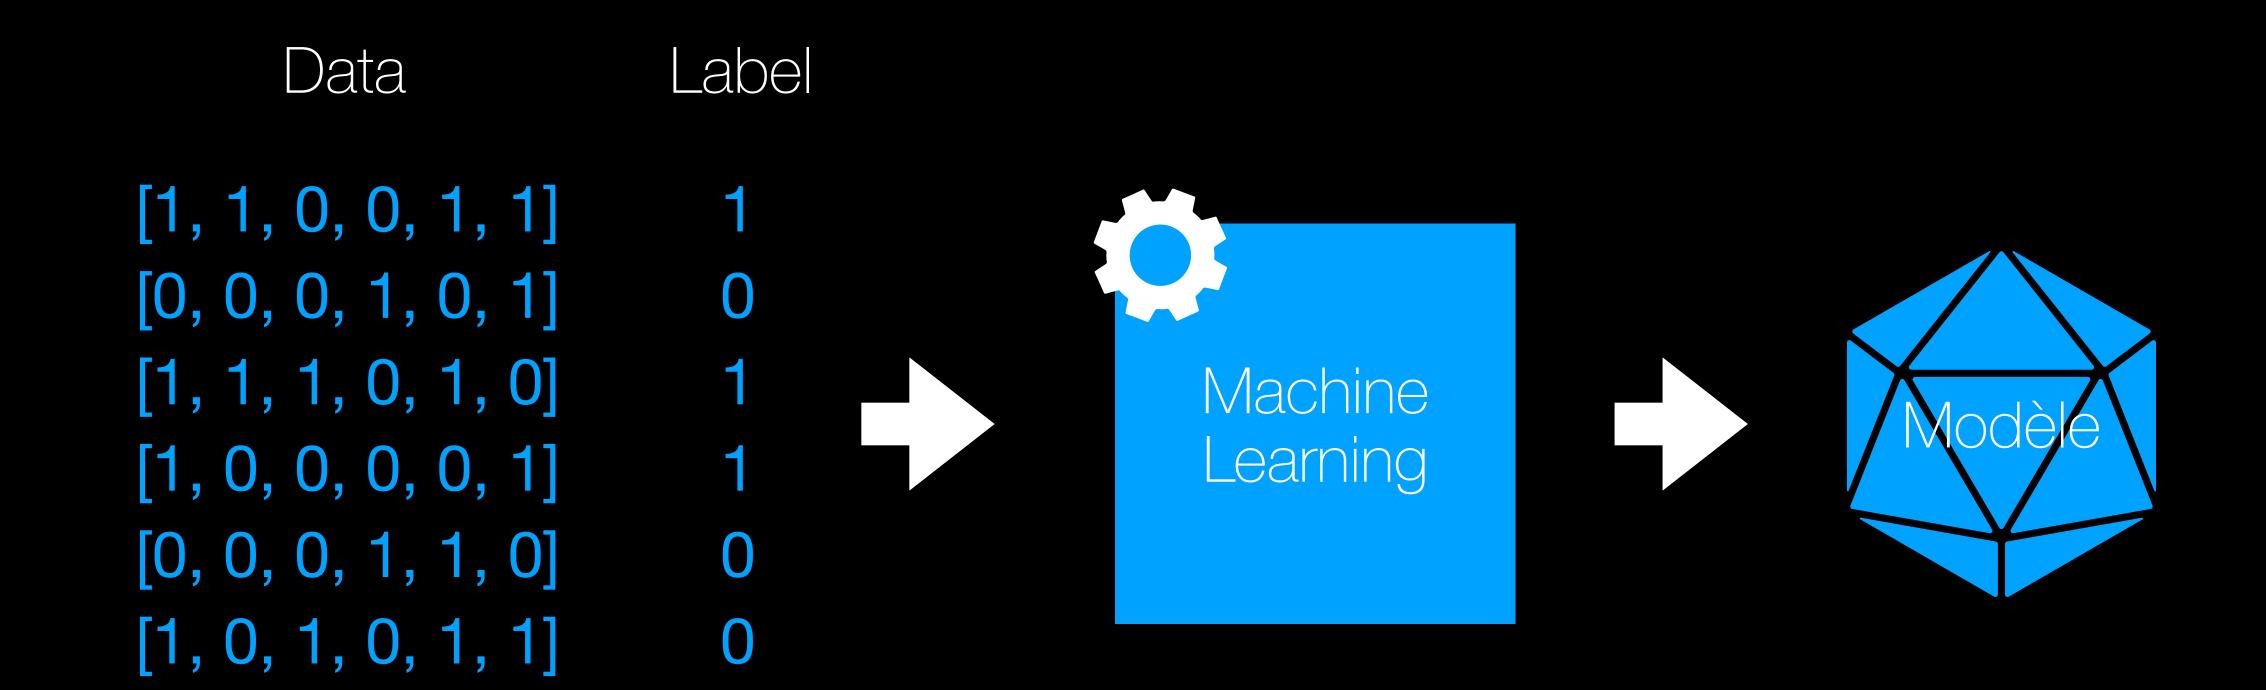
transfer \$10 to our PayPal account at prince@test.com. Once we receive the

money, we will start the transfer.

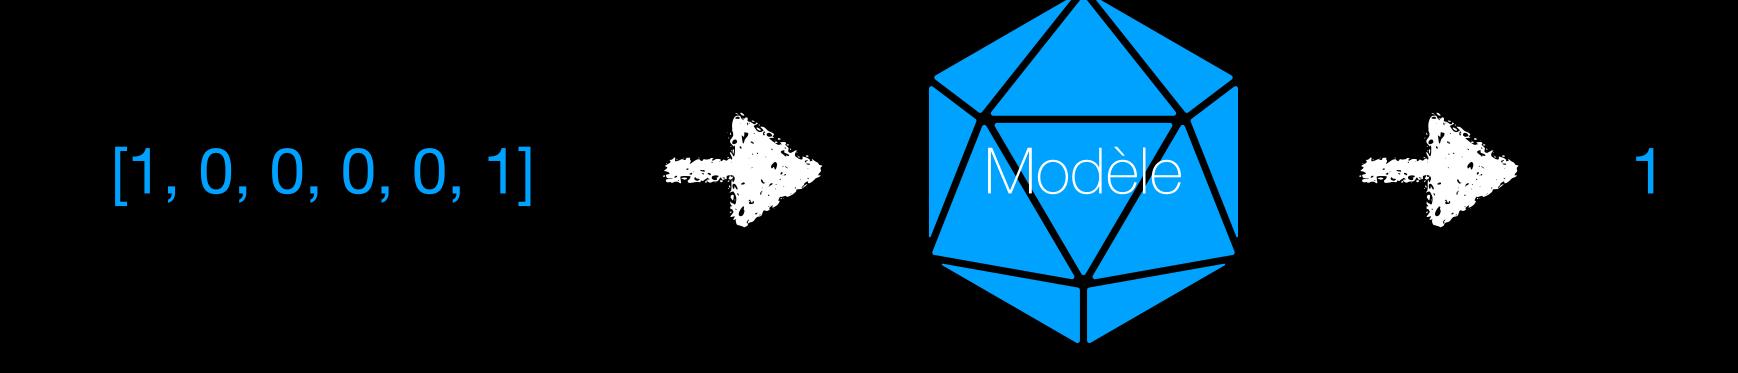
Congratulations again!

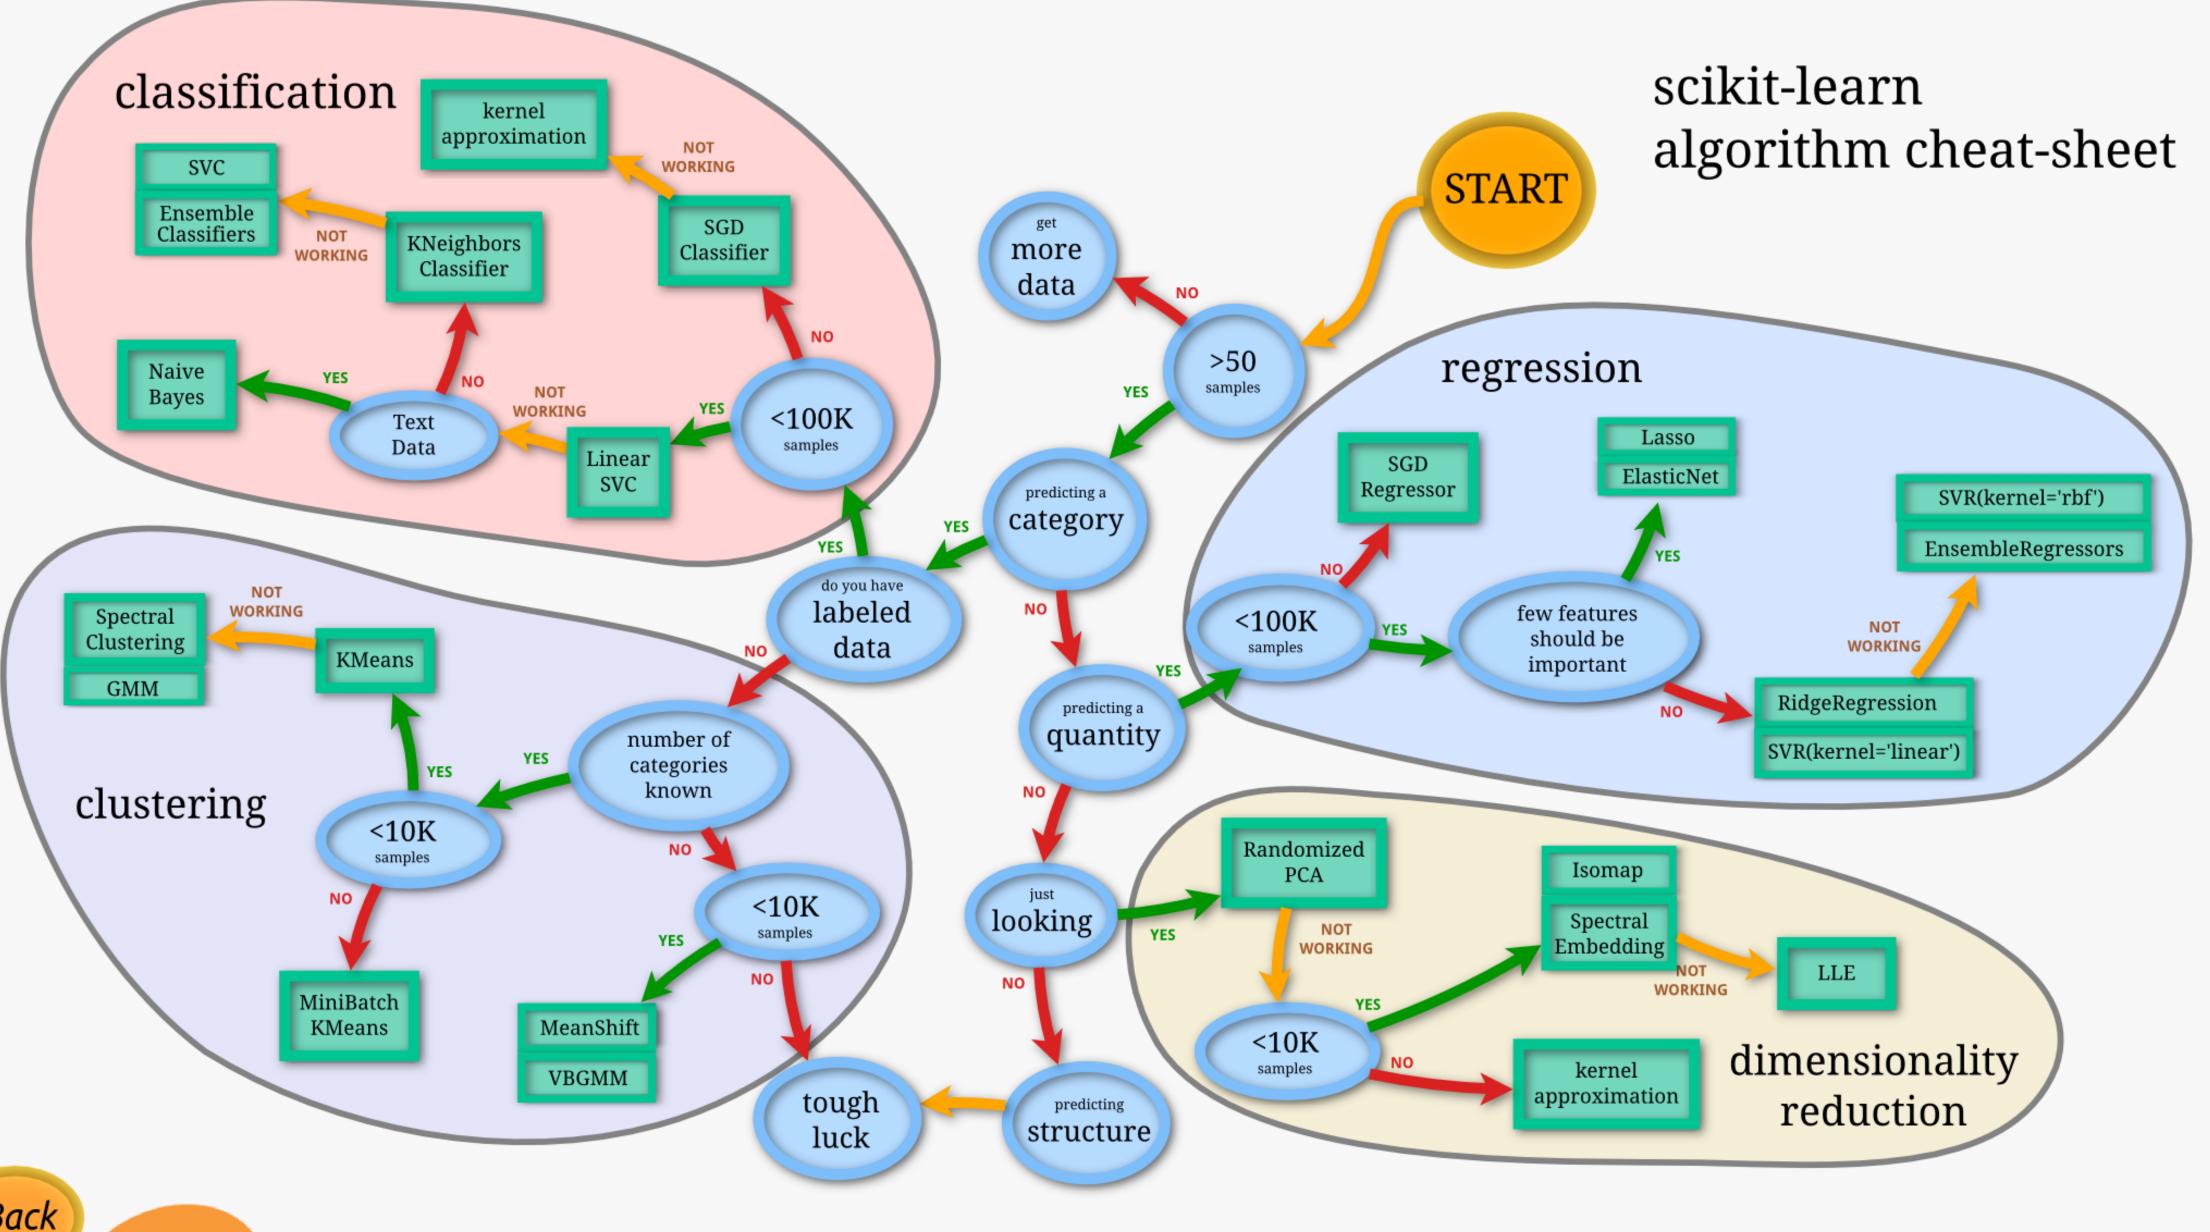


Pipeline ML



Utilisation du modèle







Résumé

Problème	Objectif	Type d'apprentissage
Régression	Prédire une valeur numérique continue (ex. : prix d'un bien immobilier)	Supervisé
Classification	Prédire une catégorie (ex. : spam ou pas spam)	Supervisé
Clustering	Regrouper des données sans connaître les catégories à l'avance	Non supervisé
Réduction de dimension	Réduire le nombre de variables en gardant la structure de l'information	Non supervisé