

# Web Scraping

BeautifulSoup



# ■ Qu'est-ce que c'est ?

Extraction de données de pages web HTML.

PythonPSFDocsPyPIJobsCommunity



Donate



GO

Socialize

AboutDownloadsDocumentationCommunitySuccess StoriesNewsEvents

```
# Python: simple arithmetic
>>> numbers = [2, 4, 6, 8]
0.5 product = 1
>>> for number in numbers:
8..     product = product * number
>>> 17 / 3 # classic division returns a float
5.666666666666667
product is: ', product)
The product is: 384
5
```

>\_

### All the Flow You'd Expect

Python knows the usual control flow statements that other languages speak the operator, `if`, and `while` with some of its own twists; of course. [More control flow tools in More Python 3](#) [Simple math functions in Python 3](#).

12345

Python is a programming language that lets you work quickly and integrate systems more effectively. >>> [Learn More](#)



#### Get Started

Whether you're new to programming or an experienced developer, it's easy to learn and use Python.

[Start with our Beginner's Guide](#)



#### Download

Python source code and installers are available for download for all versions!

Latest: [Python 3.13.7](#)



#### Docs

Documentation for Python's standard library, along with tutorials and guides, are available online.

[docs.python.org](#)





#### Jobs

Looking for work or have a Python related position that you're trying to hire for? Our **relaunched community-run job board** is the place to go.

[jobs.python.org](#)

## ■ Qu'est-ce que c'est ?





## ■ Quand l'utiliser ?

Récupérer les **données** en ligne pour effectuer des **analyses, comprendre et prendre des décisions.**

Automatisation

Veille informationnelle

Veille concurrentielle

Agrégation de contenu

Science des données



## ■ Cadre légal




Scraper des **données publiques** est totalement **légal**.

Ce qui pose problème :

- données personnelles
- propriété intellectuelle



# ■ Éthique



S'interroger l'impact du scraping

- Site Web = business
- Copyright
- Scraping agressif = risque interruption de service
- Scraper n'apporte aucune valeur pour le site



# ■ Scraping irresponsable




Conséquences :

- Blocage IP
- Infractions = sanctions judiciaires
- Dédommagement (propriété intellectuelle)



## ■ Scraping responsable



Suggestions :

- Introduire des délais dans les scripts
- Considérer les heures creuses (moins de traffic)
- Consulter les CGU + robot.txt
- Contacter directement l'administrateur



# ■ Notions Web utiles pour le scraping | HTML

## STRUCTURE GLOBALE

```
<!DOCTYPE html>
<html>
<head>
<meta>
<title>
<body>
```

## STRUCTURE DU CONTENU

```
<header>
<nav>
<main>
<article>
<section>
<aside>
<footer>
```

## TEXTE ET TITRES

```
<h1>
<h2>
<h3>
<h4>
<p>
<strong>
<em>
<code>
<span>
```

## LISTES

```
<ul>
<ol>
<li>
<dl>
<dt>
<dd>
```

## TABLEAUX

```
<table>
<caption>
<thead>
<tbody>
<tfoot>
<tr>
<th>
<td>
```

## REGROUPEMENT / MULTIMEDIA

```
<div>
<figure>
<img>
<figcaption>
```



# ■ Notions Web utiles pour le scraping | css

## CLASSE

```
.container {  
    color: red;  
}
```

```
<div class="container">  
    <h1>Foo Bar</h1>  
</div>
```

## IDENTIFIANT

```
#container {  
    color: red;  
}
```

```
<div id="container">  
    <h1>Foo Bar</h1>  
</div>
```

## PSEUDO CLASSE

```
<section>  
    <p>Paragraphe 1</p>  
    <div>  
        <p>Paragraphe 2</p>  
    </div>  
    <p>Paragraphe 3</p>  
</section>
```


```
div > p  
section p  
section > p  
section p:first-child  
section p:last-child  
section p:nth-child(2)  
section p:nth-child(even)  
section p:nth-child(odd)  
section p:nth-of-type(2)  
section p:nth-of-type(even)  
section p:nth-of-type(odd)
```



# ■ BeautifulSoup

## Parser HTML

```
<!DOCTYPE html>
<html lang="fr">
<head>
  <meta charset="utf-8">
  <meta name="viewport" content="width=device-width, initial-scale=1">
  <title>Démo HTML</title>
</head>
<body>
  ...
  <footer id="footer">
    <p>© 2025 – Démo HTML. <a href="#haut">Haut de page</a></p>
  </footer>
</body>
</html>
```



BeautifulSoup

```
...
.find()
.find_all()
.select_one()
...
```



# ■ BeautifulSoup | exercice

<https://quotes.toscrape.com>

Objectifs :

- quotes.csv (contenu, auteur, tags, pas de doublon)
- authors.csv (pas de doublon)
- automatiser le chargement des urls






# Piloter un navigateur

Ouvre un lien dans un navigateur



```
...  
    .find_element(By...)   
    .find_elements(By...)   
    .click()   
    .send_keys(...)   
    ...
```

Charge le contenu  
(rendu HTML issue du JS)





# ■ Selenium | exercice

<https://sandbox.oxylabs.io/products>

Objectif :

- cars-games.csv (toutes les infos : titre, description, prix, état du stock, note etc... + date et heure))