




Big Data



"By 2025, there will be 175 zettabytes of data globally, with 80% of that data being unstructured. Ninety percent of unstructured data is never analyzed."

- **Forbes**




Activités quotidiennes

Ex : Transactions financières internes,
Gestion des stock



Produits et services

Ex : Statistiques de vente



Données accessibles

Ex : Bases de données publiques,
Études de marché




Données clients et partenaires


Ex : Avis clients, Données transactionnelles



Déluge de données

Les différentes formes de données





Caractéristiques du Big Data (4V)

VOLUME

Quantité colossale de données générées en continu.

Exemples:

- réseaux sociaux
- capteurs IoT
- transactions bancaires
- vidéos YouTube

VELOCITY

Génération et traitement rapide des données pour en tirer de la valeur.

Exemples:

- analyse en temps réel de fraudes bancaires
- notifications en direct (Twitter)
- capteurs dans les voitures connectées

VARIETY

Données non homogènes, provenant de sources multiples et variées.

Exemples:

- bases de données relationnelles (structurées)
- images et vidéos (non structurées)
- logs de serveurs
- fichiers JSON/CSV.

VERACITY


Les données peuvent être incomplètes, bruitées ou biaisées. Leur valeur dépend de leur crédibilité.

Exemples:

- fake news
- erreurs de saisie en BDD
- données manquantes.

Scaling : vertical vs horizontal

Vertical




8 vCPU
32 GB RAM
128 GB disk



16 vCPU
64 GB RAM
256 GB disk





32 vCPU
64 GB RAM
1 TB disk




64 vCPU
128 GB RAM
5 TB disk


Horizontal



Contraintes des BDD relationnelles




Traitement distribué de données massives



MapReduce : exemple 1


Produit	Montant
Pomme	€3
Poire	€2
Pomme	€4
Banane	€5
Poire	€6



Map



Shuffle



Reduce


MapReduce : exemple2

Carte	Montant	Lieu	Heure
C1	50	Paris	10:00
C1	1200	Lyon	10:05
C2	15	Lille	10:10
C1	2000	New York	10:20
C2	25	Lille	10:25



(C1, (50, Paris, 10:00))
(C1, (1200, Lyon, 10:05))
(C2, (15, Lille, 10:10))
(C1, (2000, New York, 10:20))
(C2, (25, Lille, 10:25))

Map



(C1, [(50, Paris, 10:00), (1200, Lyon, 10:05), (2000, New York, 10:20)])
(C2, [(15, Lille, 10:10), (25, Lille, 10:25)])

Shuffle



Reduce

(C1, FRAUDE)
(C2, NORMAL)



Plateforme logicielle open source pour le stockage distribué et le traitement distribué de très grands ensembles de données sur des clusters d'ordinateurs construits à partir de matériel standard.



2003-2004 **Google**

GFS + MapReduce

2005 **Doug Cutting**

HDFS + MapReduce

2006 **Apache Foundation**

Projet

2007 **Yahoo!**

Contribution massive

2008 **Maturité**

Standard open source Big Data

<https://static.googleusercontent.com/media/research.google.com/en//archive/gfs-sosp2003.pdf>

<https://static.googleusercontent.com/media/research.google.com/en//archive/mapreduce-osdi04.pdf>



Open Source

Adoption / contribution mondiale

Coût réduit

Matériel standard

Horizontal Scaling

Ajout facile de nœuds

Flexibilité

Tous types de données

Écosystème riche

Hive, Pig, HBase, Spark, etc.

Tolérance aux pannes


Auto-réplication et redémarrage automatique




Les 3 composants de Hadoop :

- **HDFS** (Hadoop Distributed File System)
- **MapReduce**
- **YARN** (Yet Another Resource Negotiator)

hadoop : HDFS



hadoop : MapReduce



hadoop : YARN

